当代人工智能实验一·文本分类实验报告

姓名：张贤柯 | 学号：10245501431 | 日期：2026-09-21
代码仓库：https://github.com/REPLACE_USERNAME/ai-lab1-text-classification

一、问题与假设

目标是把一段新闻文本 x 自动归入 10 个预定义类别之一 $y \in \{0,\dots,9\}$，训练数据带标签，属监督学习。实验前明确两条假设：**H1**（方法前提）话题相近的文章用词也相近，词频统计足以支撑分类；**H2**（待检验）文本中的邮件头（From/Subject 等）是与话题无关的格式噪声，去除后模型更好。评价指标在实验前确定为验证集**准确率**（主）与**宏平均 F1**（辅），全程按此选择方案，不因结果改变标准。

二、数据与划分

课程提供训练集 7368 条（含标签）与无标签测试集 2457 条。10 个类别基本均衡（占比 9.57%~10.14%，图 1）；无缺失值与重复样本；字符数中位数 1139、均值 1855、最长 160616，呈长尾分布。测试集全程封存，仅最终预测一次。验证集按类别分层、以 8:2 从训练集划出（1474 条），固定随机种子 42。泄露排查：全库仅 12 条样本的**引文**中出现过 `Newsgroups:` 字段（非样本自身头部），不存在直接标签泄露，H2 的检验是公平的。

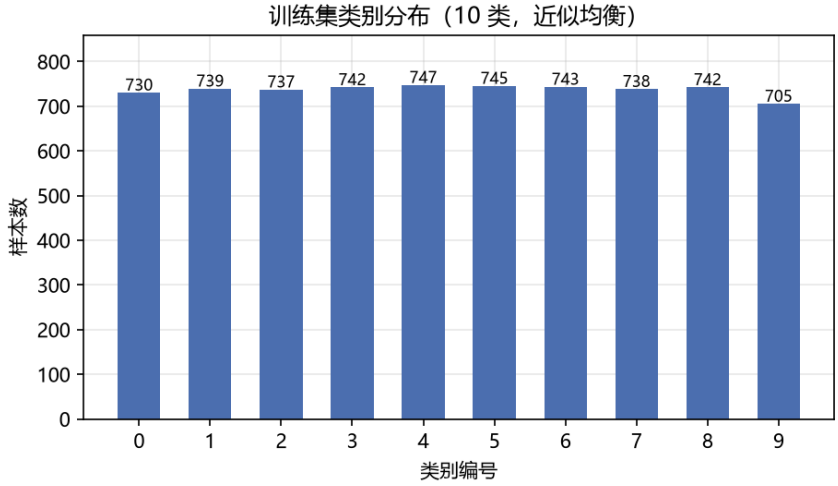


图 1 训练集类别分布（10 类近似均衡）

三、特征工程与预处理

采用 TF-IDF 将文本转为数值向量：$\text{TF-IDF}(t,d) = \text{TF}(t,d) \times \text{IDF}(t)$，其中 $\text{IDF}(t) = \log[(1+N)/(1+\text{DF}(t))]+1$，词频给高频词以权重、逆文档频率压制"the、and"这类无区分度的词。预处理设为三种强度（none 原样 / light 去邮件头 / heavy 再删引文与标点数字），向量化变体包括词级 TF-IDF、词袋计数、停用词、二元词组、sublinear 对数词频、以及词+字符级 n-gram 拼接，共 10 种配置 F1–F10 用于消融。所有词表与 IDF 统计量**只在训练折上拟合**，验证/测试仅做变换，杜绝数据泄露。

四、模型与实验设置

四种课程要求的分类器统一在相同划分、种子与指标下比较，每次只改变一个因素。超参搜索范围按课程 `TUNING.md` 建议设定（表 1），逐模型用验证集挑选最优。

模型	核心思想（一句话）	搜索范围	最优配置	验证准确率
朴素贝叶斯	贝叶斯定理 + 特征独立假设，按词计数投票	$\alpha \in \{0.01,0.1,0.5,1\}$	α=0.1	0.8765
SVM	最大化分类间隔的线性分类器，C 控制对错分的容忍度	线性 C∈{0.1,1,10,100}；RBF C×γ	RBF C=10, γ=scale	0.8874
逻辑回归	线性模型输出类别概率，C 为正则化强度倒数	$C \in \{0.1,1,10,100\}$	C=10	0.8799
MLP	带隐层与 ReLU 激活的全连接网络，α 为 L2 系数	层结构 (100)/(200)/(100,50)/(400)，α∈{1e-4,1e-2}	(100,), α=1e-4	0.8847

表 1 模型原理、搜索范围与最优配置（基线特征配置：去邮件头 + TF-IDF 5000 维）

五、结果与分析

5.1 基线对比

四模型基线准确率集中在 0.868~0.885（图 2）：MLP 略高但训练耗时是朴素贝叶斯的 70 倍。所有方法均远超随机水平（10%），验证了 H1——词频统计足以支撑分类。

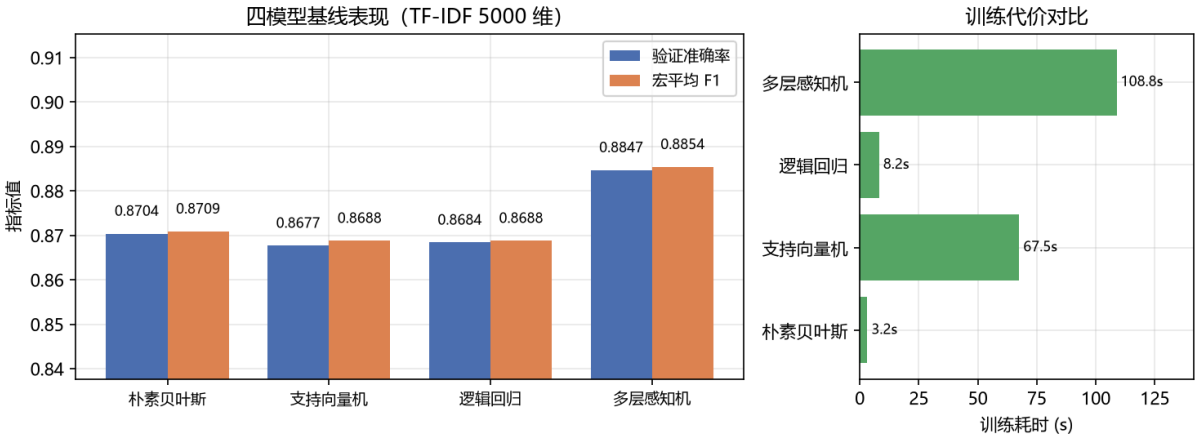


图 2 四模型基线表现与训练代价（验证集，TF-IDF 5000 维）

5.2 超参数调优

调参曲线见图 3。朴素贝叶斯 α 从 1.0 降至 0.1 提升 0.6 个百分点：减弱拉普拉斯平滑使长尾判别词获得更大权重。逻辑回归对 C 最敏感（C=10 比 C=0.1 高 7.6 个百分点），说明弱正则有利于充分拟合高维稀疏特征。SVM 线性核与 RBF 核（0.8874）基本打平，佐证 TF-IDF 空间已近似线性可分。MLP 加宽（200/400）或加深（100,50）均无提升，增大 α 反而下降——容量不是瓶颈。

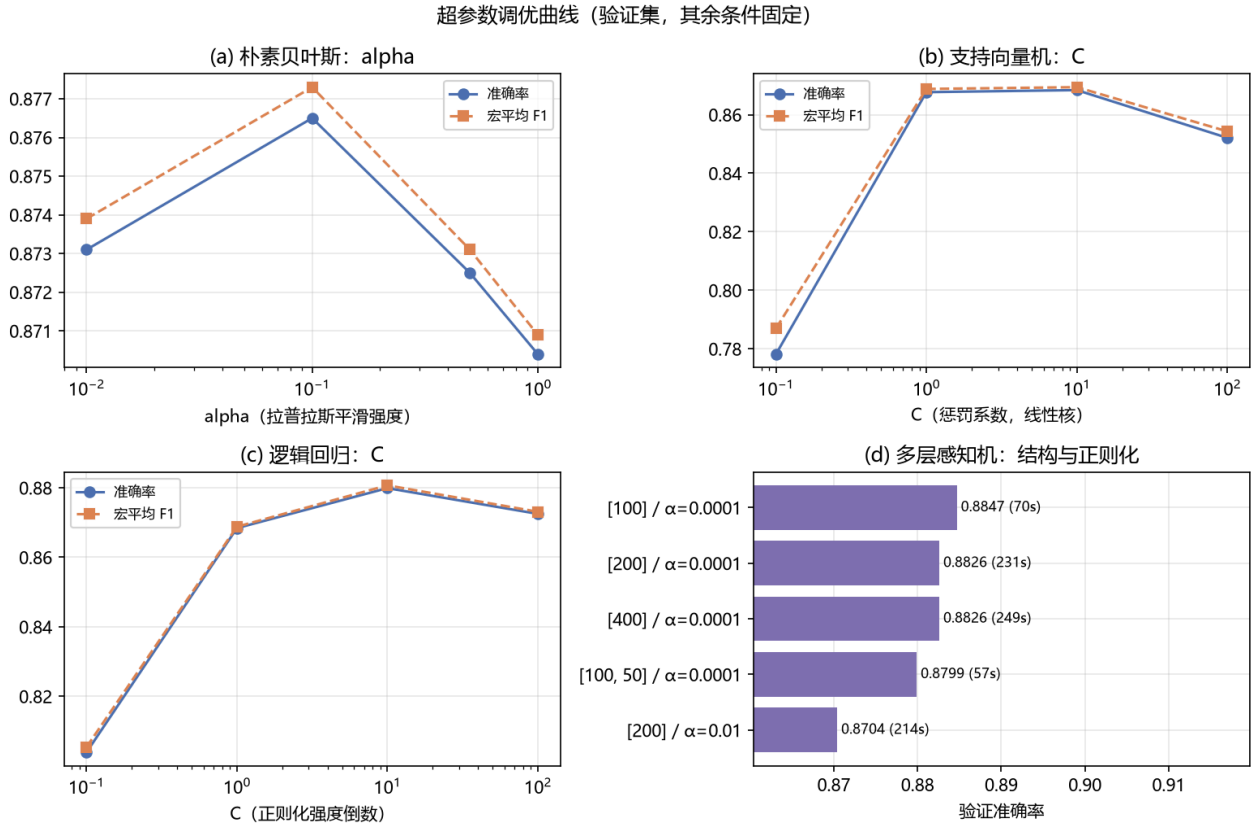


图 3 超参数调优曲线（验证集，其余条件固定）

5.3 特征工程消融

以逻辑回归（C=10）为固定分类器，10 种特征配置的验证集表现见图 4（SVM 下结论一致）。三个主要发现：**① 假设 H2 被推翻**——保留原始文本的 F1（0.9132）比去邮件头的 F2（0.8799）高 3.3 个百分点，Subject/Organization 等字段携带真实的话题弱线索；**② 词表大小是单项最大杠杆**——5k→3.3 万全词表（F8，0.9077）提升约 4 个百分点，超过任何换模型与调参的收益；**③ 过度清洗有害**——heavy 清洗（F3，0.7978）大幅低于基线，因为 IDF 本已自动压制高频无信息词，删标点/数字反而误伤了有判别力的 token。字符级 n-gram 拼接（F9，0.9125）比 F8 高 0.5 个百分点，但训练贵约 10 倍。

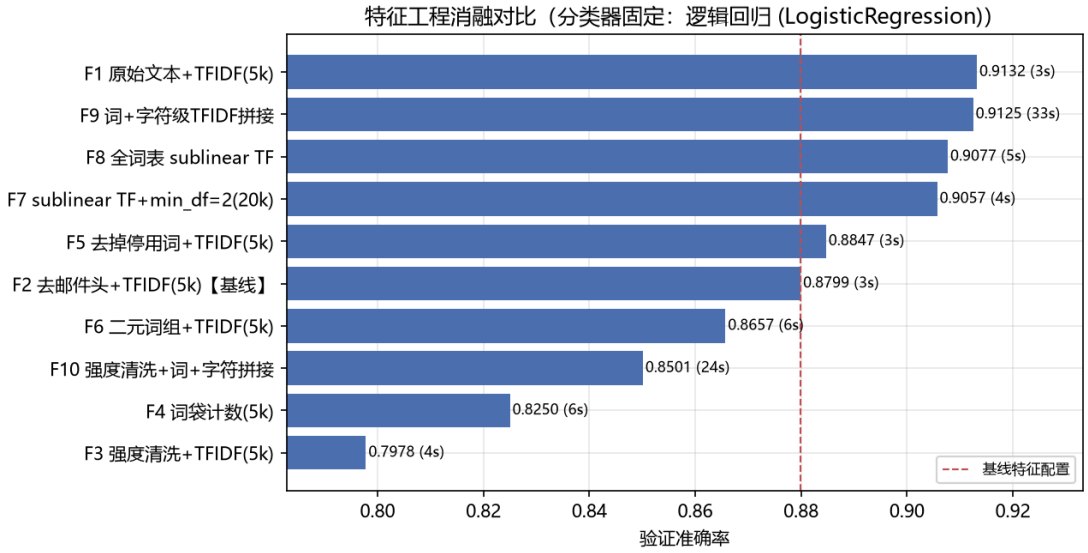


图 4 特征工程消融对比（分类器固定：逻辑回归 C=10）

5.4 集成探索

在 F1 特征上尝试软投票集成：NB+LR 为 0.9125，NB+LR+SVM 为 0.9145，仅比单个 LR（0.9132）高 0.13 个百分点，而训练耗时增加约 60 倍。按评分标准"综合考虑验证集性能与模型复杂度"，集成方案不采用。

5.5 错误分析

最终模型在验证集上的混淆矩阵与各类别指标见图 5、图 6。最弱类别为类 2（F1=0.8136）与类 1（0.8701），二者互相混淆：观察高频词发现两类都以硬件术语为主（scsi/drive/card 与 ax/max/windows），语义近邻导致线性边界模糊，属**任务固有的类间歧义**而非模型缺陷。类 9（F1=0.9929）等类别词表区分度强，几乎无错分。

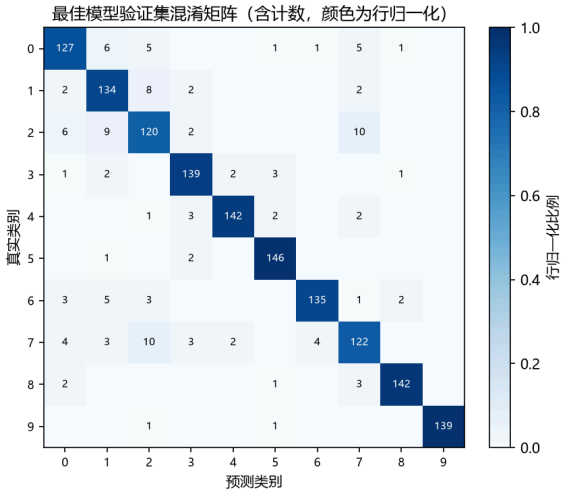


图 5 混淆矩阵（颜色为行归一化）

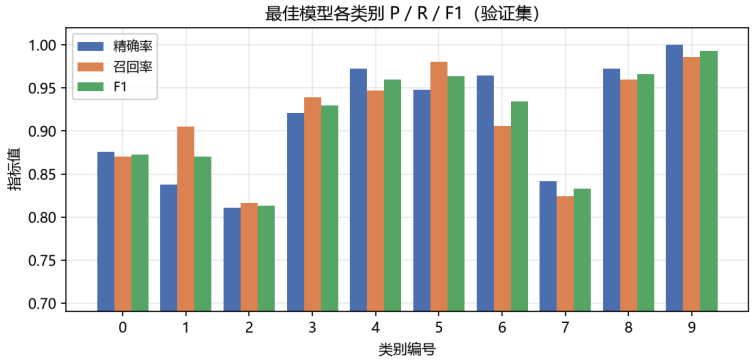


图 6 各类别 P/R/F1（验证集）

六、最终方案与评估

综合性能与复杂度，最终方案为：**原始文本 + TF-IDF(5000 维) + 逻辑回归(C=10)**（单模型、训练约 3 秒）。5 折交叉验证在全训练集上的结果为准确率 **0.9097 ± 0.0120**、宏平均 F1 **0.9103 ± 0.0118**（表 2）；留出验证集 0.9132。随后用全部 7368 条训练数据重训模型，对 2457 条测试集做一次性预测，保存为 `predictions.csv`（各类别预测数 224~262，与训练分布一致）。注意全训练集拟合准确率达 0.999，与交叉验证约 0.910 之间存在约 9 个百分点的泛化差距——高维稀疏特征下线性模型对训练集过拟合是常态，这正是必须依赖验证集/交叉验证选型、而不能看训练分数的原因。

折次	1	2	3	4	5	均值 ± 标准差
准确率	0.9159	0.9193	0.8928	0.9192	0.9016	**0.9097 ± 0.0120**
宏平均 F1	0.9167	0.9197	0.8934	0.9194	0.9023	**0.9103 ± 0.0118**

表 2 最终方案 5 折分层交叉验证（全训练集，seed=42）

七、复现说明

环境：Python 3.13.2 / numpy 2.5.2 / pandas 3.0.5 / scikit-learn 1.9.0 / matplotlib 3.11.1；全局随机种子 42；分层 8:2 划分；测试集封存。代码仓库提供完整脚本，依次运行 `run_experiments.py --stage eda/baseline/tuning/features/final`

即可从原始数据复现全部结果表（`results/tables/`）与图表（`results/figures/`），最终由 `--stage final --feature F1 --model lr --C 10.0` 生成提交文件 `predictions.csv`（2457 行、无表头、每行一个 0-9 整数，与课程样例格式一致）。

八、思考与扩展

1. **为什么 SVM 与逻辑回归在文本数据上表现好？** TF-IDF 把文本映射到高维稀疏空间，话题相近的文档落在相近的方向簇中，类别间近似线性可分；线性模型参数少、配合正则化不易过拟合，且 IDF 已隐式完成"特征选择"。朴素贝叶斯受词独立假设限制，MLP 则因容量过剩而更易过拟合，故线性模型胜出。
2. **MLP 能否通过加深加宽提升？** 本实验证据不支持：从 (100,) 到 (400,) 或 (100,50) 验证集均无提升（图 3d）。训练集拟合已达 0.999，说明瓶颈在泛化而非表示能力；在更大的特征（如 F9 拼接）上或许有微弱空间，但代价不成比例。
3. **TF-IDF 之外还有哪些表示？** 词袋计数（本实验 F4 明显更差）；Word2Vec/GloVe 等稠密词向量（需语料与均值池化，可解释性弱）；BERT 等预训练模型微调（可达 0.96+，但超出课程经典算法的范围）。本实验以字符级 n-gram 拼接做了轻量探索（F9），收益约 0.5 个百分点。

九、结论与局限

结论：① 该 10 分类任务在 TF-IDF + 线性模型框架下即可达约 0.91 的验证集准确率，验证了 H1；② 邮件头是信息而非噪声（H2 被推翻），词表规模是比模型选择与调参更重要的因素；③ 遵循"验证集选型、测试集封存、固定种子"的规范，全部结果可复现，最终方案逻辑回归 C=10 兼顾了性能与复杂度。

局限：单一划分与单次随机种子（已用 5 折 CV 缓解波动）；未引入外部词向量与预训练模型；超参网格取值较粗；测试集无标签，其真实性能无法在本实验中观测。