当代人工智能实验一·文本分类实验报告

张贤柯（10245501431）· 2026-09-21 · 代码仓库：github.com/REPLACE_USERNAME/ai-lab1-text-classification

一、问题与假设

将新闻文本 x 归入 10 个预定义类别之一 $y\in\{0,\dots,9\}$，属监督学习。实验前明确两条假设：**H1**（方法前提）话题相近的文章用词相近，词频统计足以支撑分类；**H2**（待检验）邮件头（From/Subject 等）是与话题无关的噪声，去除后模型更好。评价指标在实验前确定为验证集**准确率**（主）与**宏平均 F1**（辅）。

二、数据与划分

训练集 7368 条（含标签），无标签测试集 2457 条全程封存、仅最终预测一次。10 类基本均衡（9.57%~10.14%），无缺失、无重复，文本长度呈长尾（中位数 1139、最长 160616 字符）。验证集按类别**分层 8:2** 划出（1474 条），固定随机种子 42。泄露排查：仅 12 条样本的**引文**中出现 `Newsgroups:` 字段（非样本自身头部），不存在直接标签泄露，H2 的检验是公平的。

三、特征工程

TF-IDF(t,d) = TF(t,d) × IDF(t)，IDF 压制"the、and"等无区分度词。预处理设三档强度（none 原样 / light 去头 / heavy 再删引文与标点），向量化变体含词袋、停用词、二元词组、sublinear 对数词频、词+字符级 n-gram 拼接，共 10 种配置 F1–F10 做消融。词表与 IDF 统计量**只在训练折拟合**，杜绝泄露。

四、模型与实验设置

模型	核心思想	搜索范围	最优	验证准确率
朴素贝叶斯	贝叶斯定理 + 特征独立假设	α∈{0.01,0.1,0.5,1}	α=0.1	0.8765
SVM	最大化间隔；C 控制对错分的容忍度	线性 C∈{0.1,1,10,100}；RBF C×γ	RBF C=10, γ=scale	0.8874
逻辑回归	线性模型输出类别概率，C 为正则化强度倒数	C∈{0.1,1,10,100}	C=10	0.8799
MLP	隐层 + ReLU 全连接网络，α 为 L2 系数	(100)/(200)/(100,50)/(400)，α∈{1e-4,1e-2}	(100,), α=1e-4	0.8847

表 1 模型与搜索范围（基线特征：去邮件头 + TF-IDF 5000；统一划分/种子/指标，一次只改一个变量）

五、结果与分析

5.1 基线

四模型基线 0.868~0.885（图 2），远高于随机水平 10%，验证 H1；MLP 略高但训练耗时是朴素贝叶斯的 70 倍。

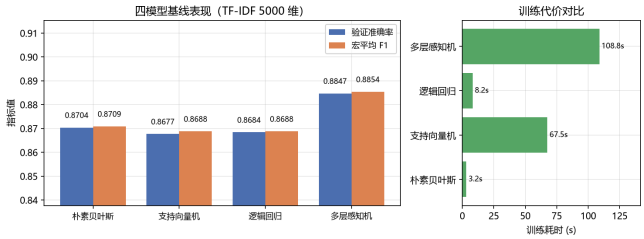


图 2 基线表现与训练代价

5.2 超参数调优

图 3：α 从 1.0 降到 0.1 提升 0.6 个百分点（弱平滑释放长尾词权重）；LR 对 C 最敏感（C=10 比 C=0.1 高 7.6 个百分点）；SVM 线性与 RBF 打平（0.8874），说明 TF-IDF 空间近似线性可分；MLP 加宽/加深/增大 α 均无提升——容量不是瓶颈。

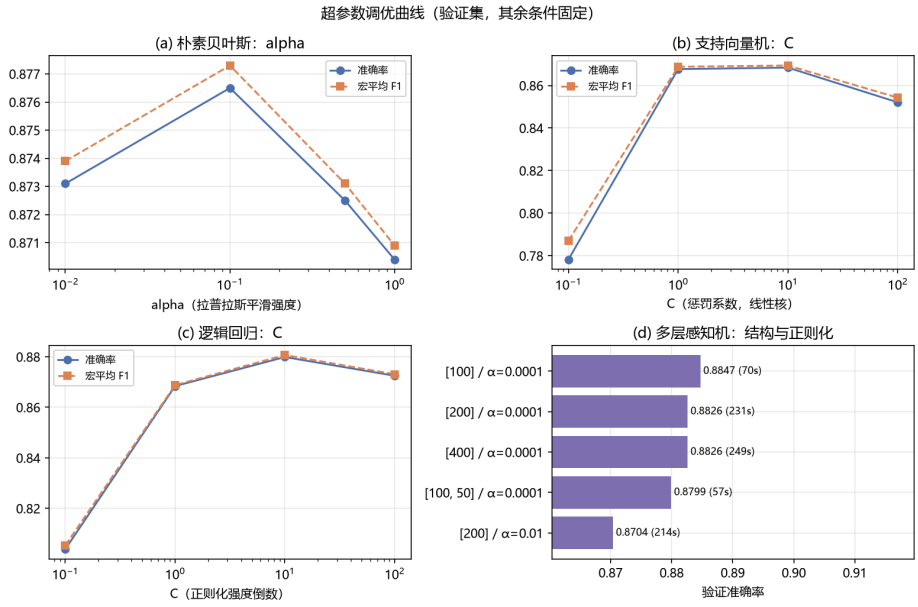


图 3 超参数调优曲线（验证集）

5.3 特征工程消融

以 LR(C=10) 为固定分类器（图 4，SVM 下结论一致）。**① H2 被推翻**：保留原始文本的 F1（0.9132）比去头的 F2（0.8799）高 3.3 个百分点，邮件头携带真实话题线索；**② 词表是最大杠杆**：5k→3.3 万全词表（F8，0.9077）提升约 4 个百分点，超过换模型与调参的收益；**③ 过度清洗有害**：F3（0.7978）因 IDF 已压制高频词、删标点/数字误伤判别词；字符级拼接（F9，0.9125）较 F8 高 0.5 个百分点但训练贵约 10 倍。

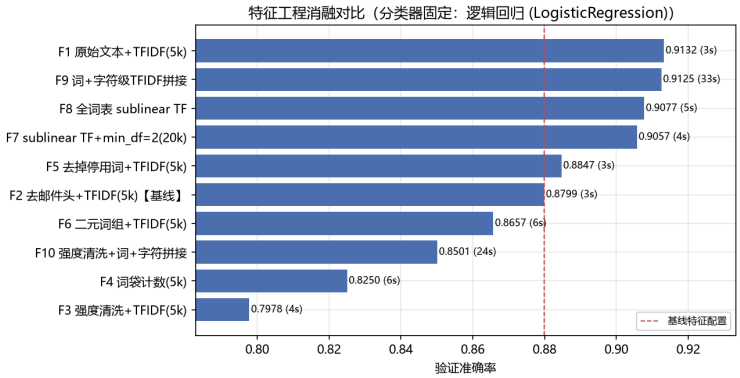


图 4 特征工程消融（分类器固定：LR C=10）

5.4 集成探索

NB+LR+SVM 软投票（0.9145）仅比单 LR（0.9132）高 0.13 个百分点、训练贵约 60 倍，按“性能与复杂度综合考虑”不予采用。

5.5 错误分析

混淆矩阵（图 5）显示类 1↔类 2 互相混淆（类 2 F1=0.8136 最低，类 9 F1=0.9929 最高）：两类高频词均为硬件术语（scsi/drive/card 与 ax/max/windows），属任务固有的类间歧义而非模型缺陷。

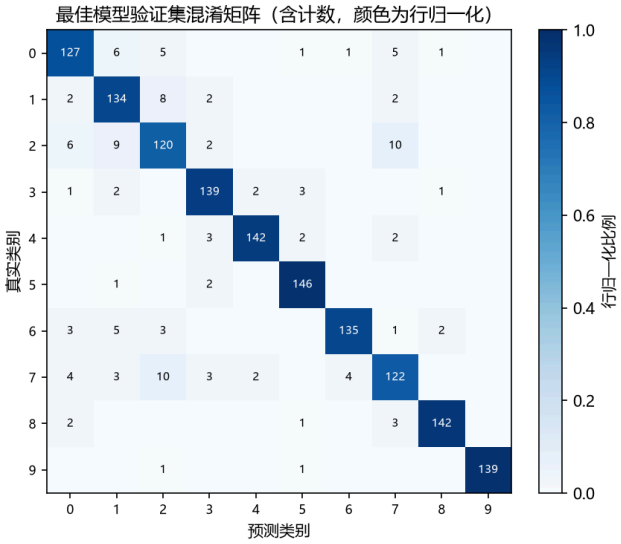


图 5 验证集混淆矩阵（行归一化）

六、最终方案与评估

综合性能与复杂度，最终方案：**原始文本 + TF-IDF(5000) + 逻辑回归(C=10)**，单模型、训练约 3 秒。5 折分层交叉验证（表 2）：准确率 **0.9097 ± 0.0120**、宏平均 F1 **0.9103 ± 0.0118**；留出验证集 0.9132。用全部 7368 条训练数据重训后，对 2457 条测试集做一次性预测，保存 `predictions.csv`（各类别预测 224~262 条，与训练分布一致）。训练集拟合准确率 0.999 与交叉验证 0.910 相差约 9 个百分点——高维稀疏下对训练集过拟合是常态，必须靠验证集/交叉验证选型，不能看训练分数。

折次	1	2	3	4	5	均值 ± 标准差
准确率	0.9159	0.9193	0.8928	0.9192	0.9016	**0.9097 ± 0.0120**
宏平均 F1	0.9167	0.9197	0.8934	0.9194	0.9023	**0.9103 ± 0.0118**

表 2 最终方案 5 折分层交叉验证（全训练集，seed=42）

七、复现说明

Python 3.13.2 / numpy 2.5.2 / pandas 3.0.5 / scikit-learn 1.9.0；全局种子 42；分层 8:2；测试集封存。仓库依次运行 `run_experiments.py --stage eda/baseline/tuning/features/final` 即可从原始数据复现全部结果表（`results/tables/`）与图表（`results/figures/`），由 `--stage final --feature F1 --model lr --C 10.0` 生成 `predictions.csv`（2457 行、无表头、每行 0-9，与样例格式一致）。

八、思考与扩展

1. **为何 SVM/LR 表现好？** TF-IDF 映射到高维稀疏空间，类别近似线性可分；线性模型参数少、正则化下不易过拟合，IDF 已隐式完成特征选择。NB 受独立假设限制，MLP 容量过剩易过拟合。
2. **MLP 能否加深加宽提升？** 证据不支持：加宽/加深验证集均无提升，训练拟合已达 0.999，瓶颈在泛化不在容量。
3. **其他表示？** 词袋（F4 更差）、Word2Vec/GloVe、BERT 微调（0.96+，超课程范围）；本实验用字符级 n-gram 拼接做了轻量探索（+0.5 个百分点）。

九、结论与局限

结论：TF-IDF + 线性模型即可达约 0.91 验证准确率（H1 成立）；邮件头是信息而非噪声（H2 被推翻）；词表规模比模型与调参更重要；全过程可复现。**局限**：单一划分（已用 5 折 CV 缓解）；未引入外部词向量/预训练模型；超参网格较粗；测试集真实性能无法观测。